



Análisis Predictivo de la Ansiedad

Cuaderno de Colab sobre salud mental -
Explorando factores predictivos mediante ciencia
de datos

Farith Obando – Nayibe Guzmán



Introducción

Importancia de predecir niveles de ansiedad para intervención temprana

Objetivo

Entender factores que influyen en ansiedad y construir modelos predictivos. Dataset: `mental_health.csv` con variables socio-demográficas y de salud mental.



Paso 1 – Carga y Preparación Inicial de Datos

01 Carga del dataset

Primero, utilizamos `files.upload()` para subir nuestro archivo CSV (`mental_health.csv`). Luego, con `pd.read_csv()`, cargamos estos datos en un DataFrame de pandas. Esto nos permite trabajar con la información de manera estructurada.

02 Traducción de columnas

Renombrado de columnas del inglés al español para facilitar la comprensión y el análisis posterior de las variables socio-demográficas y de salud mental.

03 Limpieza y revisión

Eliminación de valores nulos, verificación de tipos de datos y revisión de la estructura general del dataset para garantizar calidad en los análisis posteriores.

04 Visualización en Colab

Uso de `df.head()` y `df.info()` en Google Colab para visualizar las primeras filas y confirmar la correcta importación de los datos antes de continuar.

Análisis Exploratorio de Datos (Parte 1)

df.info() y df.describe()

Funciones esenciales para entender la estructura del dataset: tipos de datos, valores no nulos, estadísticas descriptivas básicas como media, desviación estándar y percentiles.

df.isnull().sum()

Identificación de valores faltantes en cada columna del dataset. Paso crítico para determinar estrategias de limpieza y preparación de datos antes del modelado.

Variables Categóricas

Análisis de distribución de Género, Ocupación, Actividad Física y Fumador mediante gráficos de barras para visualizar frecuencias y patrones en la población de estudio.

Variables de Salud

Exploración de Alcohol, Depresión, Ansiedad y Agotamiento. Gráficos de conteo para identificar prevalencia y relaciones preliminares entre factores de salud mental.



Distribución de Variables Numéricas

Distribución de Edad

Histogramas revelan concentración entre 25-45 años. Distribución ligeramente sesgada a la derecha con menor representación de adultos mayores en el dataset.

Tiempo de Pantalla

Análisis del tiempo de pantalla diario muestra patrones de uso entre 4-8 horas promedio. Se identifican valores atípicos que superan las 12 horas diarias.

Horas de Sueño

Distribución centrada en 6-7 horas. Se observa sesgo hacia menos horas de sueño, patrón preliminar relevante para correlacionar con niveles de ansiedad.

Construcción y Evaluación del Primer Modelo

Variable objetivo: 'Ansiedad';

'Depresión' como predictor

Preparación: one-hot encoding,
exclusión de ID_Persona

División de datos: 80%

entrenamiento, 20% prueba

Modelo: Regresión Lineal

Métricas: MAE, MSE, RMSE, R^2

www.analisispredictivo.com





Paso 4: Reentrenamiento con Características Específicas

Actividad_Fisica_Low, Ocupacion_Desempleado,
Nivel_Estres, Agotamiento

Variables adicionales: Horas_Sueño,
Puntuacion_Interaccion_Social, Depresion

Proceso similar de entrenamiento y evaluación
80/20


Comparación de desempeño: R^2 y métricas de error
vs modelo inicial





Paso 5 – Modelo Basado en la Matriz de Correlación

Depresion, Nivel_Estres,
Tiempo_Pantalla_Diario
Uso_Redes_Sociales, Horas_Sueño
Actividad_Fisica_Low, Agotamiento
Entrenamiento y evaluación final





Evaluación Comparativa de Modelos

Métricas de Rendimiento

- Modelo 1 (Todas las variables):
MAE: 1.82 | MSE: 5.21 | RMSE: 2.28 | R^2 : 0.06
- Modelo 2 (Selección manual):
MAE: 1.85 | MSE: 5.34 | RMSE: 2.31 | R^2 : 0.05
- Modelo 3 (Correlación):
MAE: 1.87 | MSE: 5.45 | RMSE: 2.33 | R^2 : 0.04

Análisis y Limitaciones

- R^2 bajo (0.04-0.06): los modelos explican solo 4-6% de la varianza
- Limitaciones de regresión lineal para fenómenos complejos
- Dataset con variables insuficientes para capturar la complejidad de la ansiedad
- Necesidad de explorar modelos no lineales



Conclusiones y Discusión

Resultados modestos

Se entrenaron múltiples modelos de regresión lineal con valores de R^2 entre 0.04 y 0.06, indicando un bajo poder predictivo con las variables disponibles.

Complejidad de la ansiedad

La ansiedad es un fenómeno multifactorial difícil de predecir únicamente con variables socio-demográficas y de estilo de vida del dataset actual.

Futuras líneas de trabajo

Explorar modelos no lineales, incorporar nuevas variables psicológicas, ingeniería de características y datasets más amplios.



Análisis Predictivo

¡Gracias!

por su atención

Sigamos explorando la salud mental juntos

